

Uso de U-Net para la segmentación de vasos sanguíneos en retinas de pacientes con retinopatía diabética

Carlos Borrego Ortiz

Dpto. Ciencias de la Computación e Inteligencia Artificial
Universidad de Sevilla
Sevilla, España
carborort@alum.us.es, cborrego2@us.es

Jaime González de Herrera Soriano

Dpto. Ciencias de la Computación e Inteligencia Artificial
Universidad de Sevilla
Sevilla, España
jaigonsor@alum.us.es, jgonzalezdeherrera@us.es

Resumen—En este informe se presenta un sistema de Inteligencia Artificial basado en la arquitectura U-Net, que combina Redes Neuronales Convolucionales (CNNs) con caminos de contracción (encoder) y de expansión (decoder), combinado con un procesamiento de los datos mediante aumento de datos (data augmentation) y padding. Se ha diseñado para generar máscaras binarias que precisen la localización de vasos sanguíneos en la retina de pacientes con retinopatía diabética.

El modelo que hemos entrenado ha tenido muy buen rendimiento, ya que ha logrado generar máscaras de gran precisión. Con su uso, los médicos oftalmólogos pueden obtener una localización automática aproximada de los vasos sanguíneos de sus pacientes, facilitando así la detección de afecciones y ahorrando tiempo y esfuerzo.

Palabras clave—Inteligencia Artificial, U-Net, retinopatía diabética, segmentación de imágenes, segmentación de imágenes médicas, padding, data augmentation, Redes Neuronales Convolucionales, CNNs, encoder, decoder, parcheado, validación cruzada, máscaras binarias, DICE score, Deep Learning

I. INTRODUCCIÓN

La retinopatía diabética es una afección de la retina provocada por la presencia de niveles elevados de glucosa en sangre, llegando a producir alteraciones en los vasos sanguíneos. Estas alteraciones dificultan el aporte de oxígeno a la retina, en la cual se pueden llegar a producir microaneurismas, hemorragias y fugas de lípidos y proteínas, pudiendo causar pérdida de visión y ceguera en los afectados. La detección precoz de estas alteraciones es sumamente importante, ya que el tratamiento de la afección es más efectivo en las fases iniciales. Para ello, se realizan exámenes de fondo de ojo, siendo el médico oftalmólogo el encargado de realizarlos para detectar la presencia de irregularidades en los vasos sanguíneos. [1]

Este informe presenta una solución software para la detección y localización automática de los vasos sanguíneos en imágenes de retina con Inteligencia Artificial, con el fin de asistir a los oftalmólogos en una evaluación inicial del estado del ojo. Esto se logra mediante el proceso de segmentación de imágenes, que consiste en la partición de una imagen en segmentos o conjuntos de píxeles que comparten características visuales similares, permitiendo así identificar estructuras específicas.

Actualmente, la disciplina de segmentación de imágenes médicas está principalmente centrada en el uso de Redes Neuronales Convolucionales (CNN), las cuales son capaces de detectar estructuras y patrones complejos en las imágenes.

El software que se presenta está basado en un modelo de Deep Learning "U-Net", el cual hace uso de CNNs que realizan una clasificación a nivel de píxel y generan máscaras binarias de alta precisión. Los desafíos que conlleva el uso de esta arquitectura son el manejo eficiente de datos volumétricos, la reducción del ruido y la garantía de que el modelo generado sea capaz de asistir en diagnósticos médicos reales. Estos problemas se han afrontado y se les ha encontrado solución a lo largo del desarrollo del proyecto, tal y como se explicará más adelante.

En este documento se presentarán las técnicas empleadas y los trabajos relacionados, se describirá el método implementado en el trabajo, se detallarán tanto los experimentos realizados como los resultados conseguidos y, por último, se indicarán las conclusiones obtenidas del trabajo.

II. PRELIMINARES

En esta sección se hace una breve introducción de las técnicas empleadas y los trabajos relacionados:

A. Métodos empleados

Los métodos y técnicas empleados han sido los siguientes:

- **U-Net:** Arquitectura diseñada originalmente para el análisis de imágenes biomédicas. Es capaz de generar máscaras binarias que delimitan estructuras complejas de alta precisión a partir de imágenes de entrada. Su estructura consiste en un camino de contracción (encoder) y un camino de expansión (decoder), además del uso de convoluciones (CNNs). [2]
- **Redes Neuronales Convolucionales (CNN):** Redes neuronales diseñadas para procesar datos en rejilla utilizando capas de convolución que detectan patrones mediante el desplazamiento de núcleos o *kernels*, permitiendo el aprendizaje de estructuras de características. [4]




Fig. 1. Arquitectura U-Net introducida en [2]

- **Encoder y decoder:** Redes neuronales que codifican y decodifican los datos de entrada para obtener información contextual. En la arquitectura U-Net, el encoder reduce la resolución espacial para entender qué hay en la imagen, mientras que el decoder proyecta estas características a la resolución original para determinar dónde se encuentran.
- **Conexiones de salto:** Conexiones que vinculan directamente las capas del encoder con las correspondientes capas del decoder del mismo nivel, transfiriendo así información de alta resolución que tiende a perderse en la fase de compresión. Permiten que la red pueda combinar la información semántica profunda con su localización espacial.
- **Parcheado:** Técnica que permite trocear imágenes grandes y difíciles de procesar en otras más pequeñas y procesables. Permite mejorar el entrenamiento a la vez que se reduce el costo computacional.
- **Máscaras:** Matrices binarias que, asociadas a su correspondiente imagen, indican qué píxeles corresponden a la información relevante (1 si es relevante, 0 si no). En nuestro caso, señalan qué píxeles corresponden a la retina. Al multiplicar una imagen por su máscara, eliminamos la información irrelevante (ruido).
- **Data augmentation:** Aumentar los datos disponibles a partir de los existentes. Las bases de datos médicas suelen ser muy pequeñas, por lo que nuestro software puede usar este método para generar nuevos datos con el fin de mejorar el entrenamiento del modelo.
- **Padding:** Añadir o recortar píxeles de las imágenes de entrada y salida del modelo. Como el tamaño deseado de las imágenes no tiene por qué coincidir con los que permite la red, se recurre al padding cuando sea necesario.
- **DICE score:** Métrica para calcular la similitud entre dos conjuntos de datos. En el contexto de la segmentación de imágenes automática, evalúa la similitud entre la segmentación predicha por el modelo y la segmentación real. [3]

- **Validación cruzada con k-pliegues:** Método que divide los datos de entrada de un modelo en k subconjuntos o pliegues. Para cada pliegue, se entrena el modelo con los datos que no le pertenecen, y después se evalúa con los datos que sí lo hacen.

B. Trabajo Relacionado

Los trabajos relacionados son los siguientes:

- **U-Net: Convolutional Networks for Biomedical Image Segmentation:** [2] Este artículo se utilizó para comprender la teoría detrás de la arquitectura U-Net y las funciones que desempeñan cada una de sus partes. La arquitectura que presenta, la cual se ha usado como referencia, se puede ver en la Fig. 1.
- **Biomedical Image Segmentation with U-Net:** [5]: Nos basamos en este notebook para diseñar el código de la carga de las imágenes, máscaras y segmentaciones manuales, así como la construcción y entrenamiento del modelo.
- **Digital Retinal Images for Vessel Extraction:** [6] : De esta base de datos se extraen las imágenes de retinas, sus correspondientes máscaras y segmentaciones manuales que se usan para el entrenamiento y validación del modelo.

III. METODOLOGÍA

La metodología implementada ha sido la siguiente:

A. Arquitectura U-Net

La arquitectura del modelo U-Net implementado se puede observar en la Fig. 2. Está formado por una capa inicial en la que se introducen las entradas con resolución original, después un camino de contracción (encoder), otro de expansión (decoder) y, por último, una capa de salida. El camino de contracción está formado por 4 bloques de encoder, de los cuales cada uno contiene:

- Dos convoluciones de núcleo 3x3 consecutivas (con padding, para que el mapa de características que resulte tenga las mismas dimensiones que la imagen original).
- Una unidad de activación ReLU tras cada convolución para introducir no linealidad en las salidas y asegurar que la información de los mapas de características sea no nula solamente cuando se detecta un patrón deseado.
- Una operación de max pooling de núcleo 2x2 que se desliza por todo el mapa de características, quedándose en cada región con el valor máximo y descartando los otros tres. Esto provoca que la resolución de la imagen se divida a la mitad.

En el la capa final del camino de contracción se realizan dos convoluciones de núcleo 3x3 con padding, seguidas cada una por una función de activación ReLU, pero no se realiza max pooling.

En el camino de expansión, tomando como origen la capa final previamente comentada, se realizan 4 bloques de decoder, de los cuales cada uno contiene:




Fig. 2. Arquitectura del modelo U-Net

$dataAugmentation(I, M, S)$

Entrada: imagen I , máscara M , segmentación manual S

Salida: nuevo I , nuevo M , nuevo S

```

1  si  $\text{random}(0, 1) < 0.5$  entonces
2       $I, M, S \leftarrow$  voltear  $I, M, S$  horizontalmente
3  si  $\text{random}(0, 1) < 0.5$  entonces
4       $I, M, S \leftarrow$  voltear  $I, M, S$  verticalmente
5  si  $\text{random}(0, 1) < 0.5$  entonces
6       $\theta \leftarrow$  ángulo aleatorio en  $\text{random}(-15, 15)$ 
7       $I, M, S \leftarrow$  aplicar rotación con ángulo  $\theta$  a  $I, M, S$ 
8  si  $\text{random}(0, 1) < 0.5$  entonces
9       $s \leftarrow$  escala aleatoria en  $\text{random}(0.8, 0.9)$ 
10      $I, M, S \leftarrow$  aplicar zoom con escala  $s$  a  $I, M, S$ 
11 devolver  $I, M, S$ 

```

Fig. 3. Algoritmo de aumento de datos

- Una convolución traspuesta de núcleo 2x2 con stride 2 (introduce un nuevo píxel con valor nulo entre cada par de píxeles) y padding, que devuelve una imagen con resolución duplicada.
- Una concatenación con el mapa de características correspondiente del camino de contracción (es decir, una conexión de salto).
- Dos convoluciones de núcleo 3x3 consecutivas con padding.

Por último, en la capa de salida se realiza una convolución de núcleo 1x1 con padding que pasa los mapas de características a una sola imagen, y se aplica una función de activación sigmoide para obtener la probabilidad de entre 0 y 1 para cada píxel (es decir, si hay o no hay vaso sanguíneo).

En cada bloque del camino de contracción, el número de filtros de las convoluciones se duplica. Por el contrario, en cada bloque del camino de expansión, esta cantidad se reduce a la mitad. En nuestro caso, tras la realización de varias pruebas hemos decidido empezar con 16 filtros de convolución, llegando en la capa más profunda a 256 filtros. Con este número de filtros y el hardware que teníamos disponible hemos conseguido los mejores resultados posibles.

El método de aumento de datos que se ha implementado para mejorar el entrenamiento del modelo se muestra en la Fig. 3. Este algoritmo se aplica aleatoriamente a las imágenes, máscaras y segmentaciones manuales de entrada del entrenamiento del modelo, generando nuevos datos. El número de datos que se generan es configurable en el programa.

B. Padding

El modelo U-Net implementado solamente admite resoluciones de imagen con altura y anchura (en píxeles) divisibles entre 16. Por tanto, se aplica padding a cada imagen de entrada (las cuales pueden tener distintas resoluciones entre sí), su máscara y su segmentación manual para adaptarlas a una resolución permisible, que también es configurable. Los píxeles se añaden o se recortan de forma equitativa a ambos lados de la dimensión deseada, dependiendo de si la altura o

la anchura son mayores o menores que las de la resolución escogida.

Las predicciones que genere el modelo tendrán la resolución configurada, independientemente del tamaño de las imágenes de entrada. Por tanto, a las segmentaciones predichas se les aplica la transformación de padding inversa para devolverlas a sus dimensiones originales.

C. Función de pérdida y métrica

Para el entrenamiento usamos como función de pérdida BCE (Binary Cross Entropy) + (1 - DICE score) y como métrica para la evaluación el DICE score.

El DICE score viene dado por la siguiente fórmula:

$$DSC = \frac{2|X \cap Y|}{|X| + |Y|} \quad (1)$$

Donde X es una segmentación real, Y es una segmentación predicha, $|X|$ e $|Y|$ son el número de píxeles con valor 1 de cada imagen y $|X \cap Y|$ es el número de píxeles con valor 1 que coinciden en ambas segmentaciones.

La función de pérdida Binary Cross Entropy (BCE) viene dada por la siguiente fórmula:

$$BCE = -\frac{1}{N} \sum_{i=1}^N [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] \quad (2)$$

Donde N es el número de píxeles de la segmentación, y_i es el valor del i -ésimo píxel de la segmentación real y p_i es la probabilidad predicha de que el i -ésimo píxel tenga valor 1.

Se ha usado como función de pérdida BCE + (1 - DICE score) porque BCE es excelente evaluando cada píxel de forma independiente para decidir si hay vaso sanguíneo o no, pero si la imagen es mayoritariamente fondo, premiará el predecir píxeles negros en vez de blancos, dando lugar así a muchos falsos negativos. A su vez, DICE score premia la similitud global entre la segmentación predicha y la real, pero penaliza con alto peso cada píxel de vaso sanguíneo no predicho, dando muchos falsos positivos. Al sumar ambas funciones, cada una cubre los puntos ciegos de la otra.

D. Entrenamiento

Para entrenar un modelo, los datos de entrada necesarios son imágenes de retinas, sus máscaras y segmentaciones correctas de sus vasos sanguíneos (en nuestro caso, hemos utilizado segmentaciones manuales realizadas por expertos) que sirvan como *ground truth*. En el conjunto de datos DRIVE 2004, hemos usado las 20 imágenes de la carpeta *training* para entrenar al modelo, junto con 50 imágenes generadas mediante aumento de datos.

Todas las imágenes de entrada han sido preprocesadas con padding para alcanzar la resolución 576x592, al ser la resolución divisible entre 16 más cercana a la de las imágenes de entrada (565x584). Al no poder usar las máscaras en el entrenamiento en sí para indicar los píxeles pertenecientes a la

retina, se ha decidido multiplicar la máscara por las imágenes de entrada para eliminar el ruido del fondo.

Se ha utilizado validación cruzada con 5 pliegues escogidos de forma aleatoria. En cada pliegue, se ha entrenado un modelo individualmente (5 modelos en total), utilizando 100 épocas y un tamaño de lote (*batch size*) de 3 imágenes. El modelo resultante en cada pliegue se ha guardado en un archivo *keras*.

IV. RESULTADOS

En esta sección se detallan tanto los experimentos realizados como los resultados conseguidos.

A. Experimentos

Para evaluar el rendimiento de los 5 modelos obtenidos durante el entrenamiento, se utilizaron las 20 imágenes de retina de la carpeta *test* del conjunto DRIVE 2004 para predecir sus vasos sanguíneos. Como en el entrenamiento, se realizó un preprocesado de las imágenes de entrada: se aplicó padding para alcanzar la resolución requerida y se multiplicaron por las máscaras.

Además, se les aplicó un postprocesado a las salidas del modelo: padding inverso para reescalarlas a su resolución original y multiplicación por las máscaras para eliminar el posible ruido generado fuera de la retina. Estas imágenes fueron guardadas en el sistema de archivos del proyecto.

Se realizaron predicciones con los 5 modelos guardados. Cada segmentación generada final fue el resultado de realizar la media entre las predicciones de cada modelo para cada imagen de entrada, obteniendo así resultados representativos del comportamiento de todos los modelos.

A la hora de medir los resultados de las segmentaciones finales, se utilizó la métrica DICE score para comprobar sus similitudes con las segmentaciones realizadas manualmente por dos expertos. Por cada predicción, se calculó el resultado de la métrica con ambas segmentaciones manuales correspondientes. Después, se calculó la media entre ambos resultados, tomando este último valor como representante definitivo del rendimiento. Se considera que el rendimiento es aceptable si dicho valor es mayor o igual a 0.75.

B. Resultados obtenidos

Los resultados obtenidos para las imágenes de entrada se muestran en la tabla I.

También se muestra una comparación entre una imagen de retina, sus segmentaciones manuales realizadas por expertos y la predicción realizada en la Fig. 4.

C. Análisis de los resultados

Se observa en la tabla I que el DICE score medio final (0.7975) supera el umbral de 0.75 definido anteriormente, al igual que todas las medias de cada imagen entre expertos, por lo que se considera que el rendimiento de los modelos es muy positivo.

Cabe destacar que los resultados obtenidos son muy estables al tener los valores mínimo (0.758) y máximo (0.837) de las medias entre expertos una diferencia del 10%.

TABLA I
RESULTADOS OBTENIDOS (DICE SCORE)

Imagen de entrada	Primer experto	Segundo experto	Media
1	0.82258445	0.8037757	0.81318007
2	0.83886254	0.8324253	0.83564392
3	0.75224966	0.7693557	0.76080268
4	0.82009536	0.80691797	0.81350666
5	0.79222596	0.80489004	0.798558
6	0.78260255	0.7692079	0.77590522
7	0.80386573	0.7913779	0.79762181
8	0.77236545	0.74994165	0.76115355
9	0.76976913	0.74645776	0.75811344
10	0.79948276	0.7928786	0.79618068
11	0.80229086	0.8063357	0.80431328
12	0.8080272	0.79454994	0.80128857
13	0.81264174	0.78427	0.79845587
14	0.81634897	0.7891849	0.802766935
15	0.80634815	0.7788882	0.792618175
16	0.8231093	0.8058636	0.81448645
17	0.7917812	0.7831718	0.7874765
18	0.81107616	0.8105422	0.81080918
19	0.85335124	0.81689864	0.83512494
20	0.8108494	0.7737287	0.79228905
Media	0.8044964	0.7905331	0.7975148




Fig. 4. Comparación entre una imagen de retina de entrada, dos segmentaciones realizadas por dos expertos y la segmentación predicha por los modelos guardados

En la comparación de la Fig. 4 se observa que la segmentación predicha es muy acertada al delimitar los vasos sanguíneos gruesos, pero es inexacta al reconocer los vasos delgados.

V. CONCLUSIONES

La arquitectura U-Net definida en este informe presenta muy buenos resultados en el ámbito de segmentación de vasos sanguíneos en imágenes de retinas. Con el uso de aumento de datos, no se requiere gran cantidad de imágenes para entrenar el modelo para obtener buenos resultados y, gracias al padding, se pueden usar imágenes de cualquier tamaño tanto para el entrenamiento como para generar las predicciones. Usando un servidor de Google Colaboratory, el entrenamiento dura 10 minutos con CPU, mostrando así el buen rendimiento y la eficiencia del modelo.

Mediante el uso de este modelo, los médicos oftalmólogos podrán realizar, de forma automática, una localización aproximada de los vasos sanguíneos de sus pacientes, útil para la detección de la retinopatía diabética u otras afecciones retinales. Esto les permitirá ahorrar tiempo y esfuerzo al no tener que realizar esta segmentación manualmente. Se destaca un margen de inexactitud con la posición o existencia de

los vasos más delgados, pero una gran certeza con los más gruesos.

Como posible mejora, se podría investigar nuevos métodos que permitan construir el modelo con un número menor de filtros sin perder rendimiento, para requerir menos memoria al ser entrenado. Además, como trabajo futuro, sería interesante diseñar un modelo capaz de detectar directamente si un paciente padece de retinopatía diabética a partir de una imagen de fondo de ojo.

REFERENCIAS

- [1] Dr. Alfredo García Layana. Retinopatía diabética. Clínica Universidad de Navarra. URL (Web): <https://www.cun.es/enfermedades-tratamientos/enfermedades/retinopatia-diabetica>
- [2] Olaf Ronneberger, Philipp Fischer, Thomas Brox. U-Net: Convolutional Networks for Biomedical Image Segmentation. URL (borrador de artículo): <https://arxiv.org/abs/1505.04597>
- [3] Dice score. OECD.AI. URL (Web): <https://oecd.ai/en/catalogue/metrics/dice-score>
- [4] Maria Vakalopoulou, Stergios Christodoulidis, Ninon Burgos, Olivier Colliot, Vincent Lepetit. Deep learning: basics and convolutional neural networks (CNN). Olivier Colliot. Machine Learning for Brain Disorders. URL (Capítulo libro): <https://hal.science/hal-03957224v2>
- [5] Saidislombek Abdusamatov. Biomedical Image Segmentation with U-Net. URL (Kaggle notebook): <https://www.kaggle.com/code/saidislombek/biomedical-image-segmentation-with-u-net>
- [6] DRIVE 2004 - Digital Retinal Images for Vessel Extraction. URL: <https://www.kaggle.com/datasets/zionfuo/drive2004>